

ANALIZA REZULTATA

1. Opis sprovedenog eksperimenta

- Korišćeni podaci:** Eksperiment je sproveden na skupu podataka koji se sastoji od ukupno 5000 slika, pri čemu je balans između slika sa automobilima (2496) i onih bez njih (2504) gotovo idealan. Slike su rezolucije 676x380 piksela. Podaci su za potrebe treniranja YOLO modela podijeljeni u tri skupa: trening (60%), validacioni (20%) i testni skup (20%)
- Primenjeni algoritam:** Odabran je **YOLOv8s (Small)** model. Izbor je opravdan potrebom za "real-time" detekcijom (brzina inferencije ~5-10ms), efikasnošću kod detekcije jedne klase i mogućnošću korišćenja *Transfer Learning-a* (pretreniranost na COCO datasetu).
- Metrike uspešnosti:** Za evaluaciju modela korišćene su standardne metrike za detekciju objekata:
 - Precision (Preciznost):** Udio tačnih detekcija u ukupnom broju predviđanja.
 - Recall (Odziv):** Sposobnost modela da pronađe sve relevantne objekte na slici.
 - mAP50 (Mean Average Precision):** Srednja preciznost pri IoU pragu od 0.5, koja daje sumarnu ocjenu kvaliteta lokalizacije i klasifikacije.
 - F1 Score:** Harmonijska sredina preciznosti i odziva

2. Prikaz i tumačenje postignutih rezultata

Model je nakon procesa treniranja i fine-tuninga postigao visoke performanse na testnom skupu podataka:

Metrika	Vrednost
Test Precision	0.9576
Test Recall	0.9328
Test F1 Score	0.9450
mAP50 (Test)	0.9650

Tumačenje: Rezultati pokazuju da model uspješno detektuje oko 93% svih automobila na slikama, dok su njegove predikcije tačne u preko 95% slučajeva. Visoka vrijednost mAP50 od 0.965 ukazuje na to da model ne samo da prepoznaje automobil, već i vrlo precizno iscrtava granične okvire (*bounding boxes*) oko njih.

3. Analiza ključnih nalaza i ograničenja

- **Snage modela:** Model pokazuje izuzetnu stabilnost i odsustvo drastičnog *overfitting-a*, što se vidi iz usklađenosti rezultata na validacionom i testnom skupu. *Transfer learning* je bio ključan jer je omogućio modelu da iskoristi prethodno naučene vizuelne karakteristike, što je rezultiralo brzom konvergencijom tokom treninga.
- **Slabosti i ograničenja:**
 - **Kvalitet podataka:** Analiza je pokazala da su bounding box-ovi u prosjeku širine 101.94px i visine 44.98px. Iako je dataset dobro balansiran po pitanju prisustva klase, model bi mogao imati poteškoća sa veoma malim objektima u daljini (zbog smanjenja rezolucije u dubljim slojevima mreže).
 - **Hardverska zavisnost:** Iako je YOLOv8s brz, maksimalne performanse (inferencija od 5-10ms) postižu se isključivo uz korišćenje GPU akceleracije (CUDA).

4. Zaključci i predlozi za unapređenje

- **Glavni uvidi:** Eksperiment je potvrđio da je YOLO arhitektura superiornija za ovaj tip zadatka u odnosu na klasične CNN klasifikatore ili sporije detektore poput Faster R-CNN-a. Postignute metrike ukazuju na to da je model spreman za primjenu u realnim scenarijima detekcije saobraćaja.
- **Stabilnost:** Model je validan i stabilan, sa visokim F1 skorom koji potvrđuje dobar balans između preciznosti i odziva.
- **Buduća istraživanja:**
 1. **Augmentacija podataka:** Uvođenje dodatnih tehnika poput nasumičnog zamućenja ili promjene osvjetljenja moglo bi povećati robusnost modela na loše vremenske uslove.
 2. **Veći modeli:** Testiranje YOLOv8m (Medium) verzije moglo bi dodatno podići preciznost, pod uslovom da hardver to podržava bez značajnog gubitka na brzini.
 3. **Višeklasna detekcija:** Proširivanje skupa podataka na druge kategorije (kamioni, motocikli, pješaci) kako bi se stvorio sveobuhvatniji sistem za nadzor saobraćaja.